

Analiza czynników wpływających na spłatę karty kredytowej

Raport z projektu zaliczeniowego

Mateusz Panek, Piotr Jasiak

2025-12-31

1. Cel Projektu i Opis Danych

Zgodnie z treścią zadania, celem projektu jest zbudowanie modelu predykcyjnego, który odpowie na pytanie: **czy klient spłaci swoje zadłużenie na karcie kredytowej w październiku?** (zmienna `default payment next month`). Dla uproszczenia nazwa została zmieniona na `default`.

Analizę przeprowadzono na zbiorze **12 000 obserwacji**. Dane historyczne obejmują okres 6 miesięcy (od kwietnia do września 2005) i zawierają:

- Zmienne demograficzne:** Limit kredytu (`LIMIT_BAL`), Płeć (`SEX`), Wykształcenie (`EDUCATION`), Stan cywilny (`MARRIAGE`), Wiek (`AGE`).
- Statusy płatności (`PAY_0` - `PAY_6`):** Kluczowa informacja o opóźnieniach. Np. `PAY_0` to status za wrzesień, `PAY_2` za sierpień itd.
- Historie finansowe:** Kwoty na wyciągach (`BILL_AMT`) oraz kwoty faktycznie wpłacone (`PAY_AMT`).

2. Eksploracja i Przygotowanie Danych


Przed modelowaniem dane wymagały czyszczenia i transformacji (*Feature Engineering*).

2.1 Naprawa anomalii

W zmiennych kategoriycznych zidentyfikowano wartości niezgodne z opisem zadania: * EDUCATION : wartości 0, 5, 6 (nieopisane w dokumentacji) scalono z kategorią 4 (Others). * MARRIAGE : wartość 0 scalono z kategorią 3 (Others).

2.2 Transformacja zmiennych finansowych

Zmienne kwotowe (np. limity i rachunki) charakteryzują się silną **asymetrią prawostronną**. Większość klientów ma niskie limity, ale istnieje grupa z bardzo wysokimi kwotami (tzw. długi ogon).



Rozkład limitu kredytowego przed i po logarytmowaniu

Decyzja: Zastosowano transformację logarytmiczną (*signed log*), aby "rozciągnąć" dane. Dzięki temu modele widzą różnice nie tylko u milionerów, ale też u klientów z mniejszym portfelem.

2.3 Standaryzacja


Wszystkie zmienne numeryczne zostały przeskalowane (średnia=0, odchylenie=1). Jest to wymóg techniczny dla algorytmów takich jak SVM czy Lasso.

Logarytmowanie zmiennej LIMIT_BAL oraz standaryzacja danych były **niezbędne dla stabilności modeli liniowych** (np. Elastic Net). Modele nieliniowe, takie jak **Random Forest** czy **SVM**, cechują się naturalną odpornością na te zjawiska, jednak ujednolicenie skali pozwala na rzetelne porównanie ich wydajności.

2.4 Analiza kluczowych zależności (EDA)

Z punktu widzenia oceny ryzyka, najbardziej aktualne informacje o zachowaniu klienta mają zazwyczaj największą wartość diagnostyczną. Z tego powodu podjęto decyzję o szczegółowej **analizie zmiennej PAY_0** (status płatności w ostatnim miesiącu przed badaniem). Celem tej analizy było sprawdzenie, czy bieżące opóźnienia w spłacie stanowią bezpośredni sygnał ostrzegawczy o nadchodzącym braku płatności (default).

Wpływ statusu płatności (PAY_0) na prawdopodobieństwo defaultu



Wnioski: Wykres potwierdza, że klienci spłacający zobowiązania terminowo (**wartości ≤ 0**) charakteryzują się niskim ryzykiem defaultu. Sytuacja zmienia się drastycznie przy opóźnieniu wynoszącym **2 miesiące i więcej** – w tych grupach odsetek dłużników staje się dominujący, co czyni tę zmienną kluczową dla skuteczności modelu.

3. Wyniki Modelowania

3.1 Dobór Metryki

Ze względu na **niezbalansowanie klas** (tylko około 23% niespłacających), standardowa **Dokładność (Accuracy)** byłaby metryką mylącą. Gdyby model przewidywał, że **każdy** klient spłaci kredyt, osiągnąłby aż **77% dokładności**, będąc jednocześnie bezużytecznym biznesowo. Z tego powodu wybrano:

1. **AUC (Pole pod krzywą ROC):** Jest **odporna na dysproporcje** i mierzy ogólną zdolność modelu do **rankingu ryzyka**.
AUC = 0.75 oznacza, że w 75% przypadków model poprawnie oceni losowego dłużnika jako bardziej ryzykownego niż rzetelnego klienta.
2. **F1-Score:** Średnia harmoniczna precyzji i czułości (Recall). Podczas gdy AUC ocenia model na wszystkich możliwych progach, F1-Score mówi o skuteczności binarnej decyzji. W niniejszej analizie, zamiast standardowego progu 0.5, **zastosowano próg 0.3**. Decyzja ta wynika z asymetrii kosztów w bankowości – koszt przeoczenia dłużnika jest wielokrotnie wyższy niż koszt błędnej odmowy kredytu rzetelnemu klientowi.

3.2 Ranking Modeli (Zbiór Testowy)

Poniżej zestawiono wyniki skuteczności przetestowanych algorytmów przy zastosowaniu progu **0.3**:


Porównanie AUC oraz F1 Score (próg 0.3) na zbiorze testowym

Model	AUC	F1 Score (0.3)
Random Forest	0.760	0.525
FDA (MARS)	0.756	0.513
Elastic Net	0.731	0.502
Group Lasso	0.730	0.500
SVM	0.708	0.481

- Random Forest** – Zwycięzca projektu. Wykazuje najwyższą zdolność do wykrywania złożonych wzorców dzięki agregacji setek drzew decyzyjnych. Uzyskał on również najwyższy F1-Score (0.525).
- FDA (MARS)** – Bardzo solidny model nieliniowy, ustępujący liderowi jedynie o 0.4 pkt procentowego w AUC.
- Elastic Net** – Solidny wynik, ale model zakłada liniowość ryzyka, co ogranicza jego skuteczność.
- SVM (Radial)** – Model okazał się najmniej skuteczny pod kątem AUC na tym zbiorze danych.

3.3 Porównanie Krzywych ROC

Poniższy wykres wizualizuje wydajność modeli. Krzywa dla modelu **Random Forest** (fioletowa) potwierdza jego zdolność do utrzymania najwyższej czułości przy niższym odsetku fałszywych alarmów.



4. Analiza Zwycięskiego Modelu: Random Forest

4.1 Charakterystyka modelu

Model Random Forest został wybrany jako rozwiązanie finalne ze względu na wysoką odporność na przeuczenie i optymalne parametry decyzyjne. Algorytm ten efektywnie przetwarza dane bez rygorystycznych założeń o ich rozkładzie, co przy analizie statusów płatności daje mu przewagę nad metodami regresyjnymi.

Jako algorytm zespołowy, Random Forest buduje **wiele niezależnych drzew decyzyjnych** na losowych podzbiorach danych, a następnie **agreguje** ich wyniki. Mechanizm ten redukuje ryzyko overfittingu i zwiększa stabilność prognoz. Dzięki równoległemu losowaniu obserwacji oraz cech, model skutecznie izoluje szum w danych kredytowych i identyfikuje złożone, nieliniowe zależności między zmiennymi.

Finalne parametry modelu:


- Liczba drzew (trees):** Ustalona na **300**, co stanowi optymalny balans między stabilnością błędu OOB a wydajnością obliczeniową.
- Liczba cech (mtry):** Każdy podział w drzewie wybierany jest spośród **2** losowo wskazanych zmiennych, co minimalizuje korelację między drzewami i zwiększa ich różnorodność.
- Minimalna wielkość węzła (node_size):** Próg **20** obserwacji zapobiega tworzeniu zbyt płytkich podziałów, wymuszając na modelu naukę bardziej ogólnych reguł zamiast zapamiętywania pojedynczych rekordów.
- Kryterium podziału (splitrule):** Zastosowano wskaźnik **Gini** (impurity), który precyzyjnie mierzy czystość węzłów przy każdym rozgałęzieniu drzewa.
- Błąd OOB (Brier Score):** Wynik na poziomie **0.1456** świadczy o bardzo dobrej kalibracji prawdopodobieństwa i trafności prognoz modelu na danych niewidocznych.

4.2 Wyjaśnienie ważności zmiennych (VIP)

Ważność zmiennych to miara określająca, w jakim stopniu każda z cech przyczyniła się do poprawy trafności klasyfikacji i redukcji niepewności modelu w procesie podejmowania decyzji

Metodologia: Wykres ważności zmiennych został wyliczony metodą **Gini Impurity**. W algorytmie Random Forest każde drzewo uczy się poprzez ciągłe dzielenie danych na **coraz "czystsze" grupy** (czyli takie, w których dominują albo sami dłużnicy, albo sami klienci spłacający terminowo).

Analiza ważności zmiennych VIP (Model Random Forest)



4.3 Jak powstaje wynik na wykresie?

- Zysk informacyjny:** Przy każdym podziale danych model sprawdza, o ile dana zmienna (np. PAY_0) pomogła uporządkować zbiór i zmniejszyć w nim chaos (nieczystość).
- Sumowanie zasług:** Wynik widoczny na osi X to suma wszystkich takich poprawek, jakie dana zmienna wniosła we wszystkich 300 drzewach.
- Wniosek:** Im wyższy słupek, tym częściej i skuteczniej zmienna ta pozwalała modelowi poprawnie rozpoznać dłużnika.

W ujęciu matematycznym, ważność zmiennej X_j (Variable Importance) jest definiowana jako suma spadku zanieczyszczenia (Gini Impurity) we wszystkich węzłach τ , w których dokonano podziału względem tej zmiennej, uśredniona po wszystkich drzewach w lesie:

$$VI(X_j) = \frac{1}{N_{trees}} \sum_T \sum_{\tau \in T: v(\tau)=X_j} \Delta i(\tau, X_j)$$

Gdzie: $\Delta i(\tau, X_j)$ to redukcja nieczystości Giniego w węźle τ po dokonaniu podziału. $v(\tau) = X_j$ oznacza, że zmienna X_j została wybrana jako optymalny predyktor w danym węźle. N_{trees} to całkowita liczba drzew w modelu.

4.3 Interpretacja Biznesowa

1. **Dominacja PAY_0 (Wrzesień):** Status płatności z ostatniego miesiąca posiada absolutnie największą wartość diagnostyczną (wskaźnik istotności **213.5**). Potwierdza to hipotezę, że najświeższa dyscyplina płatnicza klienta jest kluczowym prognostykiem jego przyszłej wypłacalności.
2. **Historia Behawioralna:** Istotne znaczenie mają również statusy z sierpnia (PAY_2) oraz kwoty ostatnich wyciągów (BILL_AMT1) i wpłat (PAY_AMT1).
3. **Marginalna rola demografii:** Model niemal całkowicie ignoruje zmienne demograficzne, co czyni proces oceny ryzyka bardziej obiektywnym i skupionym na faktach finansowych.

4.4 Wizualizacja działania modelu (Scatter plot)

Zrozumienie, w jaki sposób model Lasu Losowego podejmuje decyzje, wymaga wyjścia poza proste statystyki. W tym celu zastosowano **scatterplot z nałożoną granicą decyzyjną** dla dwóch kluczowych zmiennych zidentyfikowanych w rankingu VIP: PAY_0 oraz BILL_AMT1 .


Dlaczego te dwie zmienne? Wybrano je, ponieważ reprezentują dwa najważniejsze wymiary ryzyka:

1. **Wymiar Behawioralny (Zachowanie)** - zmienna PAY_0 : Mówi nam o aktualnej dyscyplinie płatniczej klienta.
2. **Wymiar Ekspozycji (Skala)** - zmienna BILL_AMT1 : Określa bieżącą wysokość rachunku, czyli faktyczne obciążenie finansowe klienta.

Dzięki ich zestawieniu na wykresie możemy sprawdzić, jak model dopasowuje **próg tolerancji na opóźnienia** w zależności od **wysokości długu**, co najlepiej obrazuje **nieliniową** naturę algorytmu oraz wykrytą wcześniej siłę interakcji między tymi parametrami.

Weryfikacja modelu: Interakcja PAY_0 i BILL_AMT1

Skala przywrócona do wartości oryginalnych (uskok na PAY_0 = 2)



4.5 Interpretacja wykresu i analiza interakcji

Wizualizacja tła (gradientu) przedstawia logikę decyzyjną modelu: przejście od koloru zielonego do czerwonego wyznacza **wzrost prawdopodobieństwa niewypłacalności klienta**. Nałożenie realnych punktów testowych na mapę prawdopodobieństwa pozwala ocenić skuteczność klasyfikacji w praktyce.

- Nieliniowa granica decyzyjna:** Wykres wyraźnie pokazuje, że granica ryzyka **nie jest linią prostą**. Największy "uskok" następuje przy wartości $PAY_0 = 2$. Model identyfikuje dwumiesięczne opóźnienie jako krytyczny próg ryzyka, po przekroczeniu którego prawdopodobieństwo defaultu drastycznie rośnie.
- Występowanie interakcji:** Klucowym wnioskiem z wykresu jest fakt, że wpływ zmiennej PAY_0 na ocenę ryzyka jest modulowany przez wysokość $BILL_AMT1$. Można zauważyć, że próg alarmowy dla zmiennej PAY_0 **nie jest stały, lecz przesuwają się dynamicznie wraz ze wzrostem $BILL_AMT1$** .
- Trafność klasyfikacji:** Wysoka zbieżność między rzeczywistymi zdarzeniami kredytowymi a mapą ryzyka wygenerowaną przez Random Forest pokazuje, że **model z dużą precyzją wyodrębnił kluczowe obszary**, w których kumuluje się największe prawdopodobieństwo braku spłaty.

4.6 Analiza siły interakcji (H-statistic)

Aby ostatecznie potwierdzić, czy model Random Forest wykorzystuje **głębokie, nieliniowe zależności**, przeprowadzono analizę **statystyką H Friedmana**. Pozwala ona matematycznie zmierzyć, w jakim stopniu prognoza modelu wynika z wzajemnego oddziaływania par zmiennych (interakcji), a nie tylko z ich sumarycznego działania.

Do analizy wybrano **Top 4 najważniejszych zmiennych** (według rankingu VIP), co pozwoliło na zbadanie kluczowych relacji przy jednoczesnym zachowaniu czytelności wyników i stabilności obliczeniowej.

Wartości statystyki H Friedmana określają, jaki procent zmienności prognoz modelu wynika z **wzajemnego oddziaływania** pary zmiennych, a nie z każdej z nich osobno. Wynik zbliżony do 0.5 oznacza, że aż połowa wpływu tych cech na ryzyko defaultu zależy od ich interakcji, co potwierdza wysoką nieliniowość modelu.



4.7 Wnioski z analizy interakcji:

1. **Potwierdzenie nieliniowości:** Wysokie wartości statystyki H dla czołowych par zmiennych są bezpośrednim dowodem na to, że Random Forest **buduje złożone reguły decyzyjne**. W modelach liniowych interakcje te musiałyby zostać zdefiniowane ręcznie, tutaj algorytm wykrył je samodzielnie.
2. **Interakcja PAY_0 i BILL_AMT1 :** Obecność tej pary w czołówce rankingu potwierdza obserwacje ze scatter plota.
3. **Zależności sekwencyjne (PAY_0 i PAY_2):** Wysoka pozycja interakcji między statusem płatności z września i sierpnia sugeruje, że model analizuje **historyczną powtarzalność** opóźnień.

Uwaga metodologiczna: Zamiast analizować setki skomplikowanych drzew z osobna, użyliśmy nowoczesnych metod wyjaśniania modeli: **ranking VIP, mapa granicy decyzyjnej i statystykę H Friedmana**. Pozwalają one w prosty sposób zrozumieć, jak model podejmuje decyzje i jakie zależności są dla niego kluczowe, co jest znacznie bardziej użyteczne niż przeglądanie tysięcy pojedynczych reguł.

5. Podsumowanie i wnioski końcowe

Analiza potwierdziła wysoką skuteczność modelu Random Forest w ocenie ryzyka kredytowego.

Główne wnioski to:

1. **Skuteczność nieliniowa:** Model Random Forest znacząco przewyższa metody liniowe dzięki zdolności do samodzielnego wykrywania złożonych zależności między cechami klienta.
2. **Kluczowe czynniki:** Największy wpływ na prognozę ma bieżąca dyscyplina płatnicza (PAY_0), szczególnie w połączeniu z historią z poprzednich miesięcy oraz limitem kredytowym.
3. **Obiektywizm i dane:** Proces decyzyjny opiera się na twardych danych behawioralnych (historia spłat), niemal całkowicie pomijając cechy demograficzne, co zapewnia obiektywizm oceny.
4. **Praktyczne zastosowanie:** Dzięki zastosowaniu metod XAI (ranking VIP, mapa granicy decyzyjnej, statystyka H) udowodniono, że logika modelu jest przejrzysta i spójna, co pozwala bankowi precyzyjnie oddzielać incydentalne opóźnienia od realnego ryzyka niewypłacalności.